# DevOps Agêntico Autônomo para Auto-Cura de Infraestrutura (IaC): Uma Revisão Sistemática da Literatura

1

***Abstract.*** *This systematic review examines how autonomous, agentic DevOps approaches interpret telemetry to diagnose incidents (RQ1) and which guardrails contain destructive actions in cloud infrastructure (RQ2). Of 18 candidate records exported from IEEE Xplore on 2026-10-01, 15 studies were included. Hybrid pipelines that combine anomaly detection with LLM reasoning prevail, but distributed traces appear in a single study. Explicit guardrails are scarce: one study gates autonomous fixes by evidence, safety and rollback feasibility; others rely on human escalation or constrained policies. No abstract mentions Infrastructure as Code tools such as Terraform.*

***Resumo.*** *Esta revisão sistemática analisa como abordagens de DevOps agêntico autônomo interpretam telemetria para diagnosticar incidentes (RQ1) e quais guardrails contêm ações destrutivas na infraestrutura em nuvem (RQ2). De 18 registros candidatos exportados da IEEE Xplore em 01/10/2026, 15 estudos foram incluídos. Predominam pipelines híbridos que combinam detecção de anomalias e raciocínio de LLMs, mas rastreamentos distribuídos aparecem em um único estudo. Guardrails explícitos são escassos: um estudo condiciona correções autônomas a evidência, segurança e viabilidade de rollback; os demais recorrem a escalonamento humano ou a políticas restritas. Nenhum resumo cita ferramentas de IaC, como o Terraform.*

## 1. Introdução

A operação de sistemas distribuídos em nuvem recai, em grande parte, sobre engenheiros de confiabilidade (SRE), que analisam sistemas, definem métricas, criam painéis e configuram limiares de alerta, um processo descrito como demorado, dependente de pessoas e muitas vezes reativo [Srinivasan et al. 2026]. Monitoramento baseado em limiares estáticos ou em regras tem dificuldade para detectar anomalias latentes ou desconhecidas em clusters Kubernetes dinâmicos [Masram et al. 2026, Aenugu 2026]. Nesse cenário, agentes autônomos baseados em modelos de linguagem de grande porte (LLMs) ou em aprendizado por reforço vêm sendo propostos para diagnosticar incidentes, sugerir correções e, em alguns casos, executá-las [Zheng et al. 2026, Nimmathi 2026]. A autonomia tem um custo: agentes LLM podem executar ações de reparo a partir de um raciocínio insuficientemente validado, o que resulta em correções erradas [Zheng et al. 2026]. Em infraestrutura em produção, uma ação inadvertida pode ser destrutiva, de modo que políticas de segurança e *guardrails* importam tanto quanto a capacidade de diagnóstico.

Este artigo apresenta uma revisão sistemática da literatura sobre DevOps agêntico autônomo para auto-cura de infraestrutura. O escopo é a atuação de agentes fora do ambiente de código local, cobrindo a gestão autônoma de Infraestrutura como Código (IaC;

Terraform, Kubernetes), o diagnóstico automático de incidentes de produção em tempo de execução e a aplicação autônoma de correções de emergência no contexto de SRE. Entre os registros recuperados, apenas um estudo sintetiza trabalhos anteriores, restrito a falhas em pipelines de CI/CD, e aponta a falta de *benchmarks* compartilhados, restrições de custo e latência e desafios de segurança e confiabilidade das abordagens baseadas em LLM [Bougad et al. 2026]. As contribuições são: (i) um protocolo de busca bilíngue (inglês e português) com critérios de inclusão e exclusão explícitos; (ii) a triagem de 18 registros candidatos, dos quais 15 foram incluídos, com justificativa para cada exclusão; (iii) uma síntese organizada por duas questões de pesquisa; e (iv) a identificação de lacunas, como a ausência de IaC nos resumos analisados e a escassez de *guardrails* explícitos. O artigo segue com o método (Seção 2), os resultados (Seção 3), a discussão (Seção 4), as ameaças à validade (Seção 5) e a conclusão (Seção 6).

## 2. Método

### 2.1. Escopo e questões de pesquisa

Os eixos temáticos principais são DevOps agêntico autônomo e SRE; os secundários, auto-cura de infraestrutura (IaC) e observabilidade em tempo real. As questões de pesquisa são:

- **RQ1:** como os agentes interpretam telemetria complexa (logs, métricas e rastreamentos distribuídos) para realizar análise de causa raiz (*Root Cause Analysis*, RCA) e propor correções em sistemas vivos?
- **RQ2:** quais políticas de segurança e *guardrails* são aplicadas para conter ações destrutivas inadvertidas na infraestrutura em nuvem?

### 2.2. Bases e *strings* de busca

Foi considerada uma base: IEEE Xplore. A consulta conceitual (DevOps Agêntico Autônomo AND (auto-cura de infraestrutura OR IaC) AND Observabilidade) foi operacionalizada em três *strings*:

**String 1 (inglês):**
```
("autonomous agent*" OR "agentic" OR "LLM" OR "large language model*") AND ("DevOps" OR "IaC" OR "Kubernetes" OR "Terraform") AND ("self-healing" OR "auto-remediation" OR "root cause analysis" OR "RCA" OR "observability" OR "guardrail*")
```

**String 2 (português):**
```
("agente autônomo" OR "agentic" OR "LLM" OR "agente inteligente") AND ("DevOps" OR "SRE" OR "Infraestrutura como Código" OR "IaC" OR "Kubernetes") AND ("self-healing" OR "auto-cura" OR "causa raiz" OR "observabilidade" OR "remediação")
```

**String 3 (ACM, inglês):**
```
("autonomous agent*" OR "agentic" OR "LLM") AND ("DevOps" OR "SRE" OR "Kubernetes" OR "IaC") AND ("observability" OR "telemetry" OR "root cause analysis" OR "RCA")
```

Na ACM, os termos de agente foram buscados em título ou resumo e os demais, no resumo. A Tabela 1 reúne os resultados registrados.

**Tabela 1. Resultados de busca registrados por base**

| Base | String | Resultado registrado | Situação |
|---|---|---|---|
| IEEE Xplore | 1 | 53 registros (43 conferências, 5 periódicos, 4 livros, 1 curso) | descartado |
| IEEE Xplore | n/r | exportação de 01/10/2026 (19h57min39s): 18 registros | corpus candidato |

### 2.3. Critérios, seleção e extração

Foram incluídos os trabalhos (I1) publicados entre 2020 e 2026; (I2) em língua portuguesa ou (I3) inglesa; (I4) publicados em conferências ou periódicos; e (I5) de acesso gratuito. O critério de exclusão (E1) elimina trabalhos que não contemplam os prismas principais do tema. Para aplicá-lo, E1 foi operacionalizado em três situações: (E1a) o agente atua no ambiente de desenvolvimento de código, e não na operação de infraestrutura ou serviços; (E1b) o LLM é a carga de trabalho gerenciada, e não o agente que opera a infraestrutura; e (E1c) o registro tem metadados contraditórios que impedem a classificação.

O corpus candidato é a exportação da IEEE Xplore de 01/10/2026 (18 registros). A triagem aplicou I1–I5 e E1 a título, resumo e palavras-chave. Para cada estudo incluído foram extraídos, dos metadados e do resumo, o foco, o ambiente e os resultados da avaliação, os sinais de telemetria, a técnica de interpretação, a saída proposta e o mecanismo de segurança. Os textos completos não foram lidos.

## 3. Resultados

### 3.1. Visão geral dos estudos

Dos 18 registros, 15 foram incluídos e 3 excluídos. Foram excluídos: um estudo de engenharia de conhecimento (*harness* e *guardrail*) para o desenvolvimento de software orientado por IA [Watanabe et al. 2026], por E1a; um estudo sobre a operação *on-premises* de LLMs em Kubernetes, em que o LLM é a carga gerenciada [Steude et al. 2026], por E1b; e um registro cujo título e palavras-chave tratam de computação quântica como serviço (QCaaS), enquanto o resumo trata de automação DevOps com *Zero Trust* para LLMs [Kumar et al. 2026b], por E1c. Esse resumo cita privilégio mínimo, microssegmentação e *policy-as-code*, e seria relevante para a RQ2 se os textos completos o confirmassem.

Os 18 registros são trabalhos de conferência (17 da IEEE e 1 da VDE), todos de 2026, adicionados à Xplore entre 6 de julho e 28 de setembro de 2026. Os 15 estudos incluídos têm de 3 a 12 páginas e vêm de 12 eventos; só o IEEE RE 2026 tem escopo declarado de engenharia de software, e os demais têm foco em áreas como redes, nuvem, inteligência artificial e dados. Nove dos 15 resumos citam Kubernetes; nenhum cita Terraform ou IaC.

A Tabela 2 caracteriza os estudos incluídos: sete tratam de diagnóstico e observabilidade, cinco de remediação, auto-cura ou otimização autônoma, e três de segurança, requisitos e síntese. Nove propõem um *framework* com avaliação experimental descrita; o ARGUS tem avaliação parcial; KubeAIOps e AstraRCA-FB não descrevem avaliação no resumo. As avaliações usam *testbeds*, cenários de falha, simulações e conjuntos de dados experimentais; somente um resumo cita ambientes corporativos *multi-cloud*, e nenhum

afirma avaliação em produção. As métricas variam (MTTR em quatro estudos; taxa de correções erradas; F1; número médio de réplicas) e os resultados são autorreportados, o que impede comparação direta.

### 3.2. RQ1: interpretação de telemetria, causa raiz e correção

A Tabela 3 resume os 12 estudos que processam telemetria ou eventos de operação; ARGUS, Staging conversacional e Síntese CI/CD tratam de segurança, requisitos e síntese.

Quatro achados respondem à RQ1. **(i) Sinais.** Métricas são o insumo mais citado (KubeAIOps, AstraRCA-FB, MDAF, LLM-NSMA e aScale), seguidas de logs (KubeAIOps, AstraRCA-FB, LogNexus, Demo-RCA e MDAF). Rastreamentos distribuídos aparecem só no AstraRCA-FB, o único a combinar métricas, logs e traços [Vani and Dadlani 2026]. **(ii) Raciocínio.** Predominam pipelines híbridos, em que um estágio clássico de detecção, correlação ou aprendizado antecede o LLM (KubeAIOps, AstraRCA-FB, Demo-RCA e MDAF). Três estudos usam recuperação (LogNexus, LLM-NSMA e AstraRCA-FB). Nove dos 12 estudos citam LLMs; os outros três usam aprendizado por reforço (MAPPO e RL híbrido) ou agentes de IA sem LLM declarado (multiagente *cloud-native*). **(iii) Arquitetura.** Quatro estudos usam múltiplos agentes (LogNexus, MAPPO, RL híbrido e multiagente *cloud-native*); o SENTINEL usa servidores MCP e um descritor de ambiente para descobrir componentes e configurar alertas e painéis de forma autônoma [Srinivasan et al. 2026]. **(iv) Da causa raiz à correção.** A correção é a etapa menos detalhada. Só o VeriOps-Agent descreve planos de correção avaliados antes da execução [Zheng et al. 2026]; o AstraRCA-FB usa correções anteriores como contexto, e o KubeAIOps entrega apenas explicações. Quatro resumos citam auto-cura (MDAF, MAPPO, RL híbrido e multiagente *cloud-native*) sem descrever o mecanismo de atuação, e nenhum cita a aplicação autônoma de correções de emergência (*patches*).

### 3.3. RQ2: políticas de segurança e *guardrails*

A Tabela 4 agrupa os mecanismos citados. Doze dos 15 estudos citam algum mecanismo, mas a maioria trata da confiabilidade do raciocínio ou da transparência, e não da contenção da ação.

Só o VeriOps-Agent descreve um mecanismo que bloqueia a ação autônoma: o portão de evidência reduziu em 50 a 55% a taxa de correções erradas em relação a agentes LLM diretos e a agentes autônomos sem verificação, com sobrecarga moderada de MTTR [Zheng et al. 2026]. SENTINEL e Demo-RCA mantêm o humano no circuito [Srinivasan et al. 2026, Tomas et al. 2026], e o aScale restringe as saídas do LLM a uma política de escalonamento [Adi et al. 2026]. Controles clássicos de segurança de infraestrutura não aparecem: privilégio mínimo, *sandbox*, *dry-run* e aprovação de mudanças não ocorrem nos resumos dos 15 estudos, *rollback* ocorre apenas no VeriOps-Agent, e a palavra *guardrail* ocorre só no ARGUS, como alvo de ataque. O ARGUS é descrito como validador integrado a pipelines de CI, e não como controle em tempo de execução [Gentyala et al. 2026].

## 4. Discussão

**Diagnóstico à frente da correção.** A literatura incluída interpreta telemetria melhor do que a converte em ação segura: sete estudos focam em diagnóstico e observabilidade

**Tabela 2. Estudos incluídos (n = 15): foco e avaliação reportada no resumo**

| Estudo | Foco | Avaliação reportada |
|---|---|---|
| KubeAIOps [Masram et al. 2026] | Anomalias e RCA | Não descrita no resumo. |
| AstraRCA-FB [Vani and Dadlani 2026] | RCA com feedback | Não descrita; cita "ganhos significativos" sem valores. |
| LogNexus [] | Logs e RCA | Conjuntos HDFS e BGL; diagnóstico por incidente em menos de 3 s (microsserviços em Kubernetes). |
| Demo-RCA [Tomas et al. 2026] | RCA conversacional | Demonstração em *testbed* contêinerizado (OWASP Juice Shop e PostgreSQL); sem métricas. |
| MDAF [] | Falhas em redes 5G/6G | *Testbed* OpenAirInterface sobre Kubernetes: F1 de até 78,6% (detecção) e 73,0% (3 min à frente); 77,8% de acerto na função de rede responsável. |
| LLM-NSMA [] | Monitoramento de borda | "Ganhos substanciais" em várias métricas; ambiente e valores não descritos. |
| SENTINEL [Srinivasan et al. 2026] | Observabilidade autônoma | Ambiente de referência *cloud-native*: menor tempo de configuração inicial e qualidade comparável à manual; sem valores. |
| VeriOps-Agent [Zheng et al. 2026] | Remediação segura | Falhas em microsserviços Kubernetes (6 categorias): $-50$ a 55% de correções erradas; causa raiz competitiva; sobrecarga moderada de MTTR. |
| MAPPO [Aenugu 2026] | Auto-cura (RL) | *Testbeds* simulados e reais: melhor que heurísticas e RL de agente único em recuperação, previsão de anomalias, MTTR e SLA; sem valores. |
| RL híbrido [Nimmathi 2026] | Operações preditivas (RL) | Nuvem híbrida simulada (500 nós, 90 dias, cerca de 1,2 milhão de eventos): MTTR de 42,6 para 29,1 min ($-31{,}6\%$); disponibilidade de 99,21 para 99,61%; $-47{,}8\%$ de intervenções manuais. |
| Multiagente *cloud-native* [Kumar et al. 2026a] | Entrega e auto-cura | Ambientes corporativos *multi-cloud*: $-65\%$ no tempo de ciclo de implantação, $-40\%$ de *toil*, $-90\%$ no MTTR. |
| aScale [Adi et al. 2026] | Auto-escalonamento | *Testbed* de 4 VMs, 5 execuções: latência abaixo do SLO de 250 ms com 4,3619 réplicas médias contra 5,3345 do HPA (Welch, significativo); o HPA teve menor latência e réplicas mais estáveis. |
| ARGUS [Gentyala et al. 2026] | Segurança de sistemas LLM | Paridade do CVSS v4.0 com a referência da FIRST (48 vetores); alinhamento arquitetural com as 10 categorias do OWASP LLM Top 10 (2025); piloto em 2 de 10 categorias. |
| Staging conversacional [] | Requisitos de agente | Grupos focais com 8 especialistas seniores: 135 requisitos. |
| Síntese CI/CD [Bougad et al. 2026] | Síntese e modelo conceitual | Sem experimento. |

**Tabela 3. Sinais, técnicas e saídas dos estudos que processam telemetria (RQ1)**

| Estudo | Sinais citados | Técnica de interpretação | Saída ou ação |
|---|---|---|---|
| KubeAIOps | Métricas de nós, de componentes Kubernetes e de aplicação; logs | *Isolation Forest* por entidade; filtro de persistência; agente LLM (LangChain) correlaciona métricas e logs | Explicação de causa raiz por e-mail |
| AstraRCA-FB | Métricas (Prometheus), traços (Jaeger), logs de implantação | Anomalia estatística; grafo do cluster; similaridade de incidentes por *embeddings*; agente LLM; feedback como recompensa | Diagnóstico com contexto de correções anteriores |
| LogNexus | Logs | *Embeddings* semânticos; LLM com RAG; orquestração multiagente por eventos; confiança estimada | Anomalias, correlação entre serviços e RCA |
| Demo-RCA | Logs em tempo real; sinais de anomalia | Ranking por correlação em grafo de dependências; LLM; interface por intenção | RCA por pod, com humano no circuito |
| MDAF | Métricas e logs de RAN, Core e Aplicação | Séries temporais (CNV-GRU); SHAP; LLM em linguagem natural | Previsão de falha; função de rede responsável |
| LLM-NSMA | Telemetria do Prometheus | LLMs locais com RAG e *function calling*; RAG de trajetórias (FAISS); modelos quantizados | Monitoramento e diagnóstico em linguagem natural |
| SENTINEL | Topologia e perfil de observabilidade (STOP) | LLM com servidores MCP descobre componentes e define estratégias de monitoramento | Alertas e painéis; escalonamento a humanos |
| VeriOps-Agent | Evidências do incidente | LLM gera causas-raiz candidatas e planos de correção | Plano pontuado; execução ou escalonamento |
| MAPPO | Telemetria do cluster, metas de serviço, incidentes passados | Agentes de RL com políticas descentralizadas e crítico centralizado | Autoescalonamento, detecção de falhas, auto-cura |
| RL híbrido | Eventos de telemetria | DQN e PPO com decisão multiagente; detecção preditiva de anomalias | Operações proativas e auto-otimizadas |
| Multiagente *cloud-native* | Vetores de contexto compartilhados | Agentes especializados (código, teste, segurança, FinOps) orientados a eventos | Entrega fim a fim; auto-cura |
| aScale | CPU, vazão, latência p95, violações de SLO, réplicas | LLM em laço fechado, sem treino offline nem previsão de carga | *Scale-out*, *scale-in* ou nenhuma ação |

**Tabela 4. Mecanismos de segurança e *guardrails* citados (RQ2)**

| Mecanismo | Estudos | O que limita |
|---|---|---|
| Portão de evidência com escalonamento | VeriOps-Agent | Pontua planos em cobertura de evidências, segurança da operação e viabilidade de *rollback*; executa só acima de um limiar calibrado; do contrário, escala a operadores humanos. |
| Humano no circuito | SENTINEL; Demo-RCA | O SENTINEL escala a humanos ao atingir seus limites de conhecimento; o Demo-RCA mantém diagnóstico e controle operacional com humano. |
| Política de ação restrita | aScale | Saídas do LLM limitadas a uma política de escalonamento; a análise de traços de decisão confirmou a aderência em *scale-out*, *scale-in* e nenhuma ação. |
| Ancoragem e confiança do raciocínio | LLM-NSMA; LogNexus; AstraRCA-FB | RAG e *function calling* contra alucinação; estimativa de confiança; feedback de engenheiros como recompensa. |
| Filtro de acionamento e saída sem execução | KubeAIOps | Só anomalias sustentadas chegam ao LLM; a saída é uma explicação por e-mail, e o resumo não cita execução de ações. |
| Validação de segurança e conformidade | ARGUS | *Red teaming* agêntico; mapeamento a sete arcabouços regulatórios; saída SARIF para GitHub Actions, GitLab CI e Azure DevOps. |
| Explicabilidade e requisitos centrados no humano | MDAF; Staging conversacional | SHAP com LLM; requisitos de agente explicável, baseado em evidências e centrado no humano. |
| Governança por diretrizes | Multiagente *cloud-native* | Diretrizes operacionais rigorosas; humanos em governança estratégica; mecanismo de prevenção de erros não detalhado. |
| Sem mecanismo descrito | MAPPO; RL híbrido; Síntese CI/CD | O MAPPO cita manter a estabilidade do sistema; a síntese aponta a segurança de abordagens com LLM como lacuna. |

e, entre os cinco de remediação ou auto-cura, só o VeriOps-Agent descreve planos de correção com critério de decisão.

**IaC fora do radar.** O escopo desta revisão inclui IaC, mas nenhum resumo cita Terraform ou IaC; Kubernetes é o único alvo de infraestrutura nomeado (9 de 15). As alegações de auto-cura referem-se a escalonamento e operação de cargas, e não à alteração autônoma de código de infraestrutura. Isso pode indicar um tema pouco explorado ou outra terminologia; só a leitura dos textos completos e novas *strings* (por exemplo, com Terraform no título) resolvem a dúvida.

***Guardrails* e evidência.** O portão do VeriOps-Agent indica que critérios explícitos reduzem correções erradas, mas é um único estudo, avaliado em cenários de falha [Zheng et al. 2026]; privilégio mínimo ou execução simulada não aparecem nos resumos. Quanto à evidência, resultados autorreportados, métricas distintas, ambientes sintéticos ou simulados e a falta de *benchmark* comum, também apontada pela síntese de CI/CD [Bougad et al. 2026], impedem agregar números: o MTTR cai 31,6% no RL híbrido e 90% no multiagente *cloud-native*, em ambientes e linhas de base diferentes [Nimmathi 2026, Kumar et al. 2026a].

## 5. Ameaças à validade

**Busca.** Só a IEEE Xplore contribuiu com registros: a *string* 1 retornou 53 resultados descartados; a ACM retornou 4.038 resultados sem triagem registrada; a SBC OpenLib não retornou resultados; e o Portal CAPES não tem resultados registrados. A janela de 2020 a 2026 não está representada, pois todos os registros são de 2026, e não há registro de *snowballing*. **Seleção.** A triagem usou título, resumo e palavras-chave, sem verificação independente registrada, e E1 depende de julgamento; por isso as três exclusões foram justificadas. **Extração.** Os dados vêm de resumos e metadados: ausências (Terraform, *patches*, controles clássicos) valem para os resumos, não para os textos completos, e o acesso gratuito (I5) não foi verificado. Um registro tem título e resumo contraditórios [Kumar et al. 2026b]. **Resultados.** Os números são autorreportados e não comparáveis.

## 6. Conclusão

Esta revisão analisou 18 registros e incluiu 15 estudos sobre agentes autônomos em DevOps e SRE. Para a RQ1, predominam pipelines híbridos que unem detecção clássica e LLMs sobre métricas e logs, com rastreamentos distribuídos raros e a etapa de correção pouco detalhada. Para a RQ2, o único mecanismo que bloqueia a ação autônoma é o portão de evidência do VeriOps-Agent; controles clássicos de segurança de infraestrutura não aparecem nos resumos. Como trabalhos futuros, propõem-se concluir a triagem dos resultados da ACM e das demais bases, ler os textos completos, aplicar *snowballing* e criar *strings* específicas para Terraform e IaC.

## Referências

Adi, D. S., Tjandra, V., and Syahputra, M. E. (2026). ascale: Lightweight intelligent kubernetes autoscaling for resource management. In *2026 International Conference on Information Management and Technology (ICIMTech)*, pages 494–499.

Aenugu, G. R. (2026). Multi-agent proximal policy optimization framework for autonomous reliability engineering in kubernetes-based cloud-native distributed systems. In

*2026 7th International Conference On Computational Vision and Bio Inspired Computing (ICCVBIC)*, pages 500–506.

Bougad, H., Elkhadir, Z., and Begdouri, M. A. (2026). Ai-driven failure management in ci/cd pipelines: From prediction to remediation. In *2026 International Conference on Circuit, Systems and Communication (ICCSC)*, pages 1–7.

Gentyala, S., Reddy, N., Deepthi, K. C., Saroja, P., Achari, K. V., and Shaik, R. (2026). Agentic security validation framework for retrieval-augmented and tool-enabled large language model systems. In *2026 7th International Conference On Computational Vision and Bio Inspired Computing (ICCVBIC)*, pages 1001–1011.

Kumar, P., vaidya, S., Srivalli, T., and vemula, G. (2026a). Cloud-native multi-agent intelligence for autonomous software delivery and enterprise workflow automation. In *2026 7th International Conference on Electronics and Sustainable Communication Systems (ICESC)*, pages 1939–1944.

Kumar, R., Upadhyay, H., Pandey, C. P., and Kumar, P. R. (2026b). Quantum computing as a service (qcaas): Architecture, orchestration, and performance tradeoffs. In *2026 International Conference on Computing Theory and Wireless Communications (ICCTWC)*, pages 1–11.

Masram, B., Wankhede, S., Bandivadekar, S., Shah, N., and Badhe, Y. (2026). Kubeaiops: An aiops framework for proactive anomaly and incident detection and root cause analysis in kubernetes. In *2026 6th International Conference on Intelligent Technologies (CONIT)*, pages 1–6.

Nimmathi, S. R. (2026). Hybrid reinforcement learning and agentic artificial intelligence framework for predictive platform operations and devops orchestration. In *2026 7th International Conference On Computational Vision and Bio Inspired Computing (ICCVBIC)*, pages 1197–1203.

Srinivasan, S., Sankararaman, G. S., and Kumar, A. K. (2026). Autonomous agent-based observability framework for cloud-native systems - sentinel. In *2026 IEEE Cloud Summit*, pages 229–234.

Steude, H. S., Moddemann, L., Kvachenok, I., Geier, C., Diedrich, A., Myschik, S., and Niggemann, O. (2026). Produktionsreifer und skalierbarer on-premises betrieb von llms. In *AUTOMATION 2026, Innovation trifft Anwendung*, pages 100–108.

Tomas, P. R., Dias, T., Neto, M., Rosa, L., Proença, J., Cruz, T., and Cordeiro, L. (2026). Demo: Intent-driven conversational root cause analysis in kubernetes using llms and dependency graphs. In *NOMS 2026-2026 IEEE Network Operations and Management Symposium*, pages 1–3.

Vani, M. and Dadlani, D. (2026). Ai-driven root cause analysis for kubernetes clusters. In *2026 IEEE 9th International Conference on Big Data and Artificial Intelligence (BDAI)*, pages 222–227.

Watanabe, K., Ogawa, H., Ito, S., Nakazawa, T., and Tsuru, K. (2026). A knowledge engineering framework for ai-driven software development: Harness, guardrail, and ai-native knowledge devops. In *2026 17th International Conference on Information, Intelligence, Systems Applications (IISA)*, pages 1–4.

Zheng, Y., Zhou, J., Hu, R., and Fang, R. (2026). Evidence-verified llm agents for safe backend incident remediation. In *2026 3rd International Conference on Image Processing and Artificial Intelligence (ICIPAI)*, pages 321–326.